

Aperçu Complet du Projet : Analyse et Nettoyage des Données D

Ce document présente une vue d'ensemble technique et fonctionnelle du projet, destinée à être partagée avec votre mentor afin qu'il puisse vous orienter et vous proposer un plan de travail détaillé.

1. Contexte, Données et Objectifs

Le Contexte Métier

Le projet porte sur l'analyse des flux de dédouanement du Sénégal via le système ORBUS géré par GAINDE 2000 (système de télédéclaration douanière). Les données couvrent la période 2020-2026 avec un volume d'environ 1,8 million de lignes (~1 Go brut).

Les Objectifs du Projet

1. Normalisation de la base : Assainir et consolider les données brutes (encodages corrompus, entités HTML, doublons). 2. **Contrôle de Cohérence (Jointures)** : Valider l'intégrité des relations entre les trois niveaux de données. 3. **Analyses Statistiques Exploratoires** : Dégager les tendances financières et logistiques. 4. **Détection d'Anomalies & Pré-ML** : Développer un algorithme de détection de la sous-évaluation douanière (fraude) et structurer les séries temporelles pour la prédiction des flux.

2. Structure et Jointures des Données (Sans En-tête à l'Origine)

Les fichiers CSV d'origine **ne contiennent pas de ligne d'en-tête** (les colonnes ne sont pas nommées). Les indicateurs de colonne ont été reconstitués et validés par l'analyse et la cohérence métier.

Les données sont structurées en trois niveaux logiques reliés :

```
DOSSIERS { int NUMERODOSSIERTPS PK string TYPE_OPERATION string MODE_TRANSPORT string  
PAYS_PROVENANCE string REGIME_DOUANIER } FACTURES { int IDTPSFACTURE PK int  
NUMERODOSSIERTPS FK string DEVISE string TYPE_FACTURE float VALEUR_TOTAL_CFA } ARTICLES {  
int IDTPSFACTURE FK int NUMERODOSSIERTPS FK string NUMEROTARIFDOUANE string  
DESIGNATIONCOMMERCIALE float VALEURCFA float QUANTITEMESURE float POIDSNET } DOSSIERS ||--||  
FACTURES : "1:1 via NUMERODOSSIERTPS" FACTURES ||--o{ ARTICLES : "1:N via IDTPSFACTURE" ``
```

Statistiques Clés de Jointure (Validées)

- Factures -> Dossiers (NUMERODOSSIERTPS) : 100.00 % de correspondance. Chaque facture est

associée à un dossier administratif unique.

- Articles -> Factures (IDTPSFATURE) : 93.58 % de correspondance. Il existe un léger écart de 6,42 % représentant des articles orphelins (sans facture associée dans la base).

3. Le Pipeline ETL (Extraction, Transformation, Chargement)

Pour traiter ce volume de données efficacement, nous avons implémenté un pipeline haute performance utilisant Polars (moteur Rust multi-threadé) et DuckDB (base de données analytique). Le nettoyage comprend :

1. Gestion des Encodages : Lecture en utf-8-sig pour supprimer les caractères BOM (ï»¿) et corriger les accents français corrompus (ex: SÃ©nÃ©gal -> Sénégal). 2. ****Décodage HTML**** : Application systématique de ``html.unescape`` pour nettoyer les textes encodés en HTML (ex: ``FCL - Conteneur personnalisé`` -> ``FCL - Conteneur personnalisé``). 3. ****Normalisations Catégorielles**** :

- Type d'Opération : Normalisation des codes d'opération :
 - I -> Importation
 - E -> Exportation
 - R -> Réexportation
 - S -> Transit
- Type de Facture : Correction des fautes de frappe (Proformau/Proformam -> Proforma et Definitive -> Définitive).
- Devises : Passage en majuscule et conversion automatique de EURO -> EUR.
- Modes de Transport : Standardisation de 10+ désignations manuelles en 5 catégories (Mer, Air, Route, Fer, Contener-Mer, Autres).
- Correction Géographique : Regroupement de 9 variations de Sénégal sous le libellé unique Sénégal.

4. Données Numériques & Doublons : Remplacement des virgules par des points décimaux, conversion en réels (Float64), suppression des doublons stricts, et écriture finale dans DuckDB (gainde_douane.db).

4. Analyses Statistiques Réalisées (Jupyter Notebook)

A. Analyse des Relations & Corrélations

- Spearman (Corrélation monotone) :
- *Poids Net vs Poids Brut* = 0,9965 (cohérence physique).
- *Valeur CFA vs Valeur FOB* = 0,9465 (cohérence financière).
- *Valeur CFA vs Quantité* = 0,4086 (les petits volumes de haute valeur modèrent la relation).

B. Test du Chi-Deux (Chi-Square)

- Hypothèse testée : Le choix de la Devise de facturation dépend-il du Mode de transport ?
- Résultat : P-Value = 0,0000e+00 (rejet total de l'indépendance).
- Conclusion : Dépendance logique totale (fret maritime international en EUR/USD vs commerce routier régional en CFA).

C. Analyse de Saisonnalité (Autocorrélation)

- Analyse du volume de création quotidien des dossiers douaniers :
- Corrélation au Lag 1 (jour précédent) : 0,3298
- Corrélation au Lag 7 (même jour de la semaine précédente) : 0,8540
- Corrélation au Lag 14 : 0,8252
- Conclusion : Saisonnalité hebdomadaire extrêmement stricte.

D. Détection des Outliers (Valeurs Atypiques)

- Calcul du seuil par la méthode de l'écart interquartile (IQR) sur la valeur des articles (VALEURCFA).
- Seuil supérieur = 9 380 161,80 CFA. Environ 16,75 % des lignes d'articles dépassent ce seuil (concentrant la majorité de la valeur totale douanière).

5. Phase Préparatoire au Machine Learning (ML)

Deux cas d'usage ont été préparés dans le notebook A1.ipynb :

Modèle A : Détection de la Sous-Évaluation Douanière

- Méthodologie : Calcul du prix unitaire par article et du Z-Score Robuste par rapport à la médiane historique de chaque code tarifaire douanier (NUMEROTARIFDOUANE).
- Alerte : Si le Z-Score unitaire $Z < -1.5$ (avec un historique ≥ 10 transactions), l'article est signalé comme SUSPECT_SOUS_EVALUATION.
- Résultat : 1 555 lignes suspectes détectées (0,13 % du total), cibles idéales pour les contrôles physiques.

Modèle B : Structuration pour le Forecasting Temporel

- Préparation de la série temporelle du nombre de dossiers quotidiens avec l'intégration de caractéristiques de décalage temporel (*Lag Features* : LAG_1, LAG_2, LAG_7, LAG_14) et d'une moyenne mobile sur 7 jours (MOYENNE_MOBILE_7J) pour lisser l'activité.

6. Questions clés à soumettre à votre Mentor

1. Modélisation ML : Quel algorithme privilégier pour le forecasting quotidien des dossiers douaniers (SARIMAX, XGBoost avec Lag Features, ou un modèle Deep Learning comme LSTM/Prophet) ? 2. ****Détection de la Fraude**** : Le Z-score robuste par code tarifaire est-il suffisant ou devrions-nous intégrer des modèles non supervisés de type **Isolation Forest** ou **Autoencoders** en utilisant également les pays d'origine et les importateurs ? 3. ****Données Manquantes**** : Comment traiter les colonnes physiques (*`POIDSNET`*/*`POIDSBRUT`*) qui présentent plus de 90 % de valeurs manquantes ? Devons-nous les exclure ou tenter des imputations par type de conteneur/code tarifaire ? 4. ****Validation Douanière**** : Y a-t-il des seuils ou des tolérances douanières réglementaires à intégrer dans nos règles d'alertes de sous-évaluation ?