

# **GAINDE 2000 / ORBUS**

## **FICHE TECHNIQUE D'ARCHITECTURE**

## **ET DATA ENGINEERING**

**Conception, Modelisation et Sécurisation des Flux de Données Douaniers**

Destinataire : Equipe d'Ingenierie des Données GAINDE 2000

Auteur : Yahya Elimane Kane

Date : 18 Juin 2026

Version : 2.0 (Specifications Architecturables)

Statut : Document Technique Officiel

## 1. Vision Architecturale et Objectifs Metier

Le guichet unique electronique pour le commerce exterieur, developpe par GAINDE 2000, est concu pour orchestrer, securiser et auditer l'integralite des formalites administratives et financieres liees a l'importation et a l'exportation de marchandises au Senegal.

La plateforme ORBUS sert de pivot centralise reliant de multiples acteurs heterogenes : les transitaires et commissionnaires agrees en douane, les inspecteurs des douanes (au niveau des differents bureaux physiques comme le Port de Dakar ou l'Aeroport Blaise Diagne), la Direction Generale des Douanes (pour le pilotage fiscal), les banques commerciales garantes des engagements financiers, et les compagnies d'assurance.

D'un point de vue technologique, l'architecture releve le defi d'ingerer et d'analyser des flux transactionnels denses tout en appliquant des regles strictes de confidentialite des donnees (Data Governance) et de cloisonnement d'accès en temps reel. Le systeme applique le principe du decouplage strict entre la couche transactionnelle (SQLite3) et la couche analytique (DuckDB).

## 2. Specifications Logiques et Gouvernance

La gouvernance des donnees de la plateforme repose sur une matrice tridimensionnelle croisant le controle d'accès base sur les roles (RBAC), la securite au niveau des lignes (RLS) et la securite au niveau des colonnes (CLS).

Le role de l'utilisateur est encode de maniere cryptographique dans le jeton JWT (JSON Web Token) lors de l'authentification. Ce jeton est valide a chaque requete HTTP par le serveur FastAPI.

La securite au niveau des lignes (RLS) restreint les lignes de la table auxquelles un utilisateur a droit d'accéder. Dans app.py, lors de l'appel a /api/dossiers-preview, les clauses SQL WHERE sont construites dynamiquement :

- Inspecteur DKP : WHERE MODE\_TRANSPORT = 'Mer'
- Inspecteur AIBD : WHERE MODE\_TRANSPORT = 'Air'
- Transitaire : WHERE NINEA\_IMPORTATEUR = '<son\_ninea>'
- Partenaire Financier : WHERE BANQUE = '<nom\_banque>' OR ASSURANCE = '<nom\_assurance>'

La securite au niveau des colonnes (CLS) applique l'anonymisation nominale pour les profils de recherche (Statisticiens et Journalistes) en remplaçant les noms originaux par un hachage deterministe :

Nom Anonymise = ENTREPRISE\_ANONYME\_ + (Hash(Nom Original) mod 10000)

Elle effectue egalement le masquage complet des scores et classes de risque douanier pour les profils non autorises.

### 3. Architecture Physique du Stockage

La couche de donnees implemente une architecture hybride permettant de separer les besoins OLAP (traitement analytique lourd) et OLTP (transactions rapides et persistantes).

Base de Donnees Analytique : DuckDB (gainde\_douane.db)

Il s'agit d'un fichier unique compresse stocke en colonnes. Les requetes d'agregation complexes sur les donnees historiques douanieres s'executent en memoire de maniere vectorisee. DuckDB tire parti des jeux d'instructions SIMD des processeurs. La connexion est ouverte en lecture seule (read\_only=True) par le serveur FastAPI pour eviter toute corruption de fichier.

Base de Donnees Operationnelle : SQLite3 (users.db)

Il s'agit d'une base relationnelle transactionnelle classique chargee de persister les etats operationnels dynamiques : comptes utilisateurs, mots de passe haches, dossiers cibles, et journaux d'audit de cybersecurite.

### 4. Le Pipeline d'Integration de Donnees (ETL)

Le pipeline ETL traite les fichiers transactionnels douaniers bruts via les etapes suivantes :

1. Extraction : Lecture des fichiers de transactions sources.
2. Standardisation Monetaire : Conversion automatique des factures en devises etrangeres (EUR, USD) en Francs CFA (XOF) en appliquant les taux reglementaires journaliers de la BCEAO a la date de creation du dossier :

Valeur CFA = Montant Declare x Taux Change BCEAO

3. Nettoyage et Deduplication : Rejet des transactions aberrantes (poids net negatif ou nul) et deduplication sur l'identifiant unique de declaration en ne conservant que la version la plus recente.

## 5. Moteur d'Analyse de Risque et Anti-Fraude

Le ciblage douanier combine deux modeles mathematiques distincts :

Detection Statistique par Z-Score (Sous-evaluation)

L'algorithme compare la valeur unitaire declaree par kilogramme d'une marchandise par rapport a l'historique des declarations pour un meme code SH. Le prix unitaire declare est compare a la moyenne et a l'ecart-type du groupe :

$$Z = (\text{Prix\_Unitaire\_Declare} - \text{Moyenne\_SH}) / \text{Ecart\_Type\_SH}$$

Tout dossier presentant un Z-Score < -2.0 est marque comme suspect de fraude de sous-evaluation douaniere.

Detection Multivariee par Isolation Forest

Un modele d'apprentissage automatique non surveille (Isolation Forest) est entraine pour isoler les observations atypiques en analysant conjointement les dimensions : Mode de transport, Pays d'origine, Regime douanier, Valeur declared, et Poids net. Un score d'anomalie superieur a 0.65 declenche une alerte de risque.

## 6. Modelisation Predictive & Forecasting

La Direction Generale dispose d'un module de forecasting d'activite et de rentrees fiscales a 30 jours.

Le serveur evalue en permanence la precision de differents modeles temporels (ARIMA, Prophet, Holt-Winters) sur un historique glissant en mesurant :

- Le MAPE (Mean Absolute Percentage Error)
- Le RMSE (Root Mean Squared Error)

Le modele affichant le MAPE le plus bas est automatiquement selectionne pour generer les predictions.

## 7. Segmentation des Importateurs (K-Means)

Un algorithme de clustering K-Means partitionne les importateurs en 4 segments d'activité. L'algorithme cherche à minimiser la variance intra-classe (WCSS) :

$$WCSS = \text{Somme } (x_i - \mu_k)^2$$

Les variables d'entrée sont l'historique financier et le volume logistique des transitaires, projetés sur une échelle logarithmique. Les segments identifiés (Grands Comptes, Opérateurs Réguliers, Acteurs Occasionnels, Profils Atypiques) permettent d'adapter les règles de ciblage automatique.

## 8. Flux de Données Événementiels et APIs

Toutes les fonctionnalités interactives sont liées via des requêtes REST JSON asynchrones :

- Simulateur de Risque Local (POST /api/inspecteur/simulate-risk)
- Recalcul de Poids (POST /api/direction/simulate-weights)
- Indice de Solvabilité (GET /api/partenaire/importer-reliability)
- Extraction CSV (POST /api/statistician/export-csv)
- Simulation d'Incident IT (POST /api/admin/simulate-incident)

Par exemple, la simulation d'incident insère une ligne d'intrusion suspecte dans SQLite3 (users.db) puis déclenche un re-rendu dynamique du tableau HTML des journaux d'audit réseau pour l'administrateur.